Основные понятия курса

Марк Блуменау

1 марта 2026 г.

Предисловие

Знание ответов на данные вопросы и возможность ответить на 4 из них за 3 минуты гарантирует студенту оценку 4 'удовл.' за экзамен. Ответы приведены такие, которые точно достаточны, но, естественно, принимается любая верная формулировка и формула. В случае опечаток незамедлительно сообщите @markblumenau.

Вопросы

1. Виды градиентного спуска и функций потерь

1. **Что такое mini-batch стохастический градиентный спуск?**
   Ответ: Обновление параметров модели на основе mini-batch, а не полного набора данных.

2. **Какова идея лежит в основе градиентного спуска?**
   Ответ: Итеративное изменение параметров для минимизации функции потерь.

3. **Что такое MSE?**
   Ответ: $\mathrm{MSE} = \frac{1}{n}\sum(y_{\mathrm{pred}} - y_{\mathrm{true}})^2$.

4. **Какую функцию потерь можно использовать для обучения в задаче классификации?**
   Ответ: Кросс-энтропия. (Любые другие корректные ответы принимаются)

5. **Что такое оптимизатор Adam?**
   Ответ: Комбинирует методы AdaGrad и RMSProp для адаптивного шага обучения.

6. **Какую проблему пытается решить моментум в градиентном спуске?**
   Ответ: Проблему застревания в неглубоких локальных минимумах.

7. **Каким методом вычисляются градиенты в нейросетях?**
   Ответ: Методом обратного распространения ошибки.

8. **Как в PyTorch называется параметр для регуляризации весов?**
   Ответ: Weight decay.

2. Linear, Dropout + Batch Normalization

1. **Что такое линейный слой (Fully Connected Layer)?**
   Ответ: Это слой, который описывается формулой: $y = xA^T + b$.

2. **Что такое Dropout (кратко)?**
   Ответ: Случайное отключение нейронов для предотвращения переобучения.

3. **Что такое Batch Normalization (кратко)?**
   Ответ: Масштабирование батча на входе в слой так, что матожидание 0, а дисперсия 1.

4. **Какие параметры используются в Batch Normalization?**
   Ответ: Параметры γ (масштаб) и β (смещение).

5. **Какова общая цель использования Dropout и BatchNorm?**
   Ответ: Улучшение обобщения и стабильности обучения модели.

6. **Какое количество параметров у Linear слоя?**
   Ответ: (Количество входов + 1) * количество выходов.

7. **Как работает Dropout с точки зрения формул?**
   Ответ: $y_{\text{dropout}} = (r \odot y)$, где $r \sim \text{Bernoulli}(p)$.

8. **Запишите формулы для вычисления Batch Normalization.**
   Ответ:
   $$\mu_B = \frac{1}{m}\sum_i x_i, \quad \sigma_B^2 = \frac{1}{m}\sum_i (x_i - \mu_B)^2, \quad \hat{x}_i = \frac{x_i - \mu_B}{\sqrt{\sigma_B^2 + \varepsilon}}, \quad y_i = \gamma\,\hat{x}_i + \beta.$$

9. **Какую роль играет функция активации ReLU?**
   Ответ: Вводит нелинейность: $f(x) = \max(0, x)$.

10. **Почему нужна нелинейность между слоями?**
    Ответ: Использование двух линейных слоев подряд эквивалентно использованию одного линейного слоя.

11. **Что такое Универсальная теорема аппроксимации? (Цыбенко)**
    Ответ: Линейная нейросеть с одним скрытым слоем может аппроксимировать любую непрерывную функцию многих переменных с любой точностью.

3. Операции в CNN

1. **Что такое свёрточный слой в CNN?**
   Ответ: Выполняет операцию свёртки изображения с фильтрами для извлечения признаков.

2. **Сколько параметров в Conv2d слое?**
   Ответ: $K \cdot K \cdot C_{in} \cdot C_{out} + C_{out}$, где K - размер ядра, C - количество каналов.

3. **Сколько умножений в Conv2d слое?**
   Ответ: $H \cdot W \cdot C_{out} \cdot (K \cdot K \cdot C_{in})$, где K - размер ядра, C - количество каналов, H и W - высота и ширина выходного тензора.

4. **Какова роль ядра свёртки?**
   Ответ: Выделяет локальные паттерны через взвешенное суммирование пикселей.

5. **Что такое stride (шаг) в свёрточном слое?**
   Ответ: Количество пикселей, на которое сдвигается фильтр при свёртке.

6. **Что такое padding в свёрточном слое?**
   Ответ: Добавление дополнительных пикселей для сохранения размерности.

7. **Что делает операция pooling?**
   Ответ: Уменьшает размерность, беря заданную функцию в заданном окне.

8. **Как вычисляется размер выходного тензора свёрточного слоя?**
   Ответ: $O = \frac{W-F+2P}{S} + 1$, где W — размер входа, F — размер ядра, P — паддинг, S — шаг.

9. **Запишите формулу свёрточной операции для изображения.**
   Ответ:

$$\mathrm{Im}^{\mathrm{out}}\,(x, y, t) = \sum_{i=-d}^{d} \sum_{j=-d}^{d} \sum_{c=1}^{c} \big(K_t(i, j, c)\,\mathrm{Im}^{in}(x + i, y + j, c) + b_t\big)$$

10. **Как изменяется размерность при max pooling?**
    Ответ: Размер $= \frac{W-F}{S} + 1$, где F — размер окна, S — шаг pooling.

11. **Что такое zero-padding и для чего он применяется?**
    Ответ: Добавление нулевых элементов по границам для сохранения размерности после свёртки.

4. Архитектуры CNN

1. **Чем характеризуется архитектура VGG?**
   Ответ: Глубокая сеть с последовательными свёрточными слоями и небольшими фильтрами.

2. **Запишите формулу остаточного блока (residual block) в ResNet.**
   Ответ: $y = F(x, \{W_i\}) + x$.

3. **Что такое ResNet?**
   Ответ: Сеть с остаточными (residual) связями, позволяющими строить более глубокие модели.

5. Задачи компьютерного зрения (CV tasks)

1. **Что такое задача классификации изображений?**
   Ответ: Определение категории объекта на изображении.

2. **Что такое задача детекции объектов?**
   Ответ: Выделение и локализация объектов с указанием их координат и категории.

3. **Что такое сегментация изображений?**
   Ответ: Разделение изображения на области, соответствующие различным объектам.

4. **Запишите формулу для вычисления IoU в детекции объектов.**
   Ответ: $\text{IoU} = \frac{\text{area(intersection)}}{\text{area(union)}}$.

5. **Как применяется Non-Maximum Suppression (NMS) в обнаружении объектов?**
   Ответ: Выбираются боксы с наибольшей уверенностью, удаляя сильно перекрывающиеся с ними.

6. **Как формализуется задача сегментации изображений?**
   Ответ: Минимизируется функция $L(\text{mask}_{\text{pred}}, \text{mask}_{\text{true}})$, например, dice loss.

7. **Как определяется метрика mAP для оценки детекции?**
   Ответ: Усреднением AP по классам. $\text{mAP} = \frac{1}{N}\sum \text{AP}_i$, где AP — площадь под кривой precision-recall.

6. Эмбеддинги

1. **Что такое эмбеддинги?**
   Ответ: Представление дискретных данных в виде плотных векторных пространств.

2. **Что такое cosine similarity для эмбеддингов?**
   Ответ: $\cos(\theta) = \frac{A \cdot B}{\|A\| \cdot \|B\|}$.

3. **Как выглядит softmax-функция для нормализации эмбеддингов?**
   Ответ: $\text{softmax}(z_i) = \frac{\exp(z_i)}{\sum_j \exp(z_j)}$.

7. RNN, LSTM, GRU

1. **Что такое RNN?**
   Ответ: Рекуррентная нейронная сеть, обрабатывающая последовательные данные с сохранением состояния (в так называемом скрытом состоянии).

2. **Что такое LSTM?**
   Ответ: RNN с ячейками памяти и гейтами для контроля потока информации, предотвращающих затухание градиентов.

3. **Что такое GRU?**
   Ответ: Упрощённая версия LSTM с двумя гейтами (обновления и сброса).

4. **Запишите формулу обновления скрытого состояния в стандартном RNN.**
   Ответ:
   $$h_t = \tanh\left(x_t W_{ih}^T + b_{ih} + h_{t-1} W_{hh}^T + b_{hh}\right)$$

9. Трансформеры

1. **Что такое механизм внимания?**
   Ответ: Attention - это способ выделить самые важные части входа для текущего шага обработки.

2. **Что означают термины Query, Key, Value?**
   Ответ: Это три представления токенов, через которые считается внимание.

   - Query (запрос) - что я ищу?
   - Key (ключ) - что я предлагаю?
   - Value (значение) - что я получу, если сопоставление подошло?

3. **Как вычисляется attention score?**
   Ответ:
   $$Attention(Q, K, V) = softmax(\frac{QK^T}{\sqrt{d_k}})V$$

4. **Почему несколько голов внимания повышают точность трансформерных моделей (по сравнению с одной головой внимания)?**
   Ответ: Потому что разные головы фокусируются на разных закономерностях в данных.

5. **Что делает position encoding и зачем он нужен?**
   Ответ: Он добавляет информацию о позиции токенов, которой обычному трансформеру по умолчанию не хватает.

6. **Что делает masked self-attention?**
   Ответ: Запрещает смотреть на токены "справа".

7. **Чем GPT отличается от BERT?**
   Ответ: GPT - Decoder, BERT - Encoder.

8. **Что такое LoRA?**
   Ответ: LoRA (Low-Rank Adaptation) - это метод дообучения больших нейросетей, при котором основные веса модели замораживаются, а обучение идёт только по небольшим низкоранговым добавкам.